

Część 1: Architektoniczna analiza porównawcza (Teoria)

Zadaniem jest opracowanie szczegółowej tabeli porównawczej dla modeli: **R-CNN**, **Faster R-CNN** oraz **SSD**. Tabela powinna zawierać następujące kryteria:

Kryterium	R-CNN	Faster R-CNN	SSD
Metoda generowania propozycji regionów	Selective Search generuje około 2000 propozycji regionów niezależnie od sieci CNN. Każdy region jest następnie osobno klasyfikowany.	Region Proposal Network (RPN) generuje propozycje regionów bezpośrednio z map cech CNN. Propozycje są współdzielone z detektorem.	Brak osobnego etapu generowania propozycji. Model wykorzystuje domyślne ramki (default boxes / anchor boxes) rozmieszczone na wielu mapach cech i od razu przewiduje klasy oraz położenie obiektów.
Podejście do treningu	Trudny, nie jest end-to-end: wieloetapowy proces: najpierw CNN do ekstrakcji cech, potem osobny klasyfikator SVM, a na końcu regresor bounding boxów.	W dużej mierze end-to-end. Historycznie stosowano także trening naprzemienny RPN i detektora, ale jest znacznie bardziej zintegrowana niż R-CNN.	W pełni end-to-end. Jedna sieć jednocześnie uczy się klasyfikacji i regresji ramek ograniczających.
Sposób radzenia sobie z wieloma skalami obiektów	Każda propozycja regionu jest wycinana z obrazu i skalowana do stałego rozmiaru wejściowego CNN. Podejście nie wykorzystuje naturalnie wieloskalowych map cech.	Wykorzystuje anchory o różnych skalach i proporcjach na mapach cech CNN. Lepiej radzi sobie z różnymi rozmiarami obiektów niż R-CNN, choć nadal może mieć problemy z bardzo małymi obiektami.	Detekcja odbywa się na wielu warstwach cech. Głębsze warstwy odpowiadają za coraz większe obiekty, co daje obsługę wielu skal.
Szybkość wnioskowania (FPS)	Bardzo niska, może być nawet < 1 FPS. Model jest zbyt wolny do zastosowań czasu rzeczywistego.	Średnia, zwykle od kilku do kilkunastu FPS w zależności od backbone'u i sprzętu. Znacznie szybszy od R-CNN, ale nadal często zbyt wolny dla real-time na słabym sprzęcie.	Wysoka, zwykle od kilkunastu do kilkudziesięciu FPS, a w lekkich wersjach nawet więcej. Model dla szybkiego wnioskowania
Wąskie gardło (Bottleneck)	Największym problemem jest wolne generowanie propozycji przez Selective Search oraz konieczność osobnego przetwarzania bardzo wielu regionów przez CNN. Dodatkowo cały pipeline treningowy jest złożony i nieefektywny	Główne ograniczenie wynika z dwuetapowości: najpierw generowanie propozycji przez RPN, a potem ich klasyfikacja i regresja. Kosztowne obliczeniowo są także operacje RoI Pooling / RoI Align	Największym kompromisem jest niższa dokładność, szczególnie dla małych obiektów. Problemem bywa też nierównowaga między tłem a obiektami podczas treningu oraz trudność doboru anchorów/default boxes

Część 2: Studium przypadku – Wybór architektury (Analiza)

Rozważ trzy scenariusze projektowe. Dla każdego z nich wybierz **jeden** z omawianych algorytmów, który najlepiej sprawdzi się w danym zadaniu, oraz szczegółowo uzasadnij swój wybór, powołując się na cechy z Części 1.

- **Scenariusz A: System unikania kolizji w dronie.** Dron porusza się z dużą prędkością i ma ograniczoną moc obliczeniową (procesor brzegowy/edge device). Musi wykrywać zbliżające się przeszkody (ptaki, drzewa, inne drony).
- **Scenariusz B: Analiza zdjęć histopatologicznych (medycznych).** System działa na potężnym serwerze w szpitalu. Jego celem jest znalezienie bardzo rzadkich i niezwykle małych komórek nowotworowych na obrazach o gigantycznej rozdzielczości. Czas analizy pojedynczego zdjęcia nie ma większego znaczenia, liczy się bezbłądność.
- **Scenariusz C: Historyczna analiza techniczna.** Wyobraź sobie, że jest rok 2014, a Ty musisz stworzyć system do tagowania zdjęć użytkowników w aplikacji społecznościowej (rozpoznawanie twarzy, zwierząt, samochodów). Nie masz dostępu do sieci *end-to-end*, ale zależy Ci na lepszej dokładności niż proste *sliding window*.

Scenariusz A: System unikania kolizji w dronie

Najlepszy wybór: SSD

Uzasadnienie

W tym scenariuszu kluczowe są bardzo szybkie wnioskowanie oraz niskie wymagania obliczeniowe, ponieważ dron musi reagować natychmiast. Opóźnienie detekcji może przełożyć się na kolizję z przeszkodą, dlatego priorytetem jest wysoki FPS, a nie maksymalizacja dokładności.

SSD jest detektorem jednoetapowym, czyli jednocześnie przewiduje klasy obiektów i ich położenie bez osobnego etapu generowania propozycji regionów. Dzięki temu działa znacznie szybciej niż R-CNN / Faster R-CNN. Szybkość jest największą zaletą w zastosowaniach czasu rzeczywistego, szczególnie w tym przypadku gdzie kompromis między dokładnością a szybkością jest uzasadniony.

Dodatkowo SSD dobrze współpracuje z lżejszymi backbonami, co czyni go bardziej praktycznym na takich urządzeniach brzegowych jak drony.

Dlaczego nie pozostałe modele?

- **R-CNN** jest zdecydowanie zbyt wolny i zbyt ciężki obliczeniowo
- **Faster R-CNN** ma wyższą dokładność, ale jego dwuetapowa natura powoduje większy czas wnioskowania, który jest nieakceptowalny dla drona

Scenariusz B: Analiza zdjęć histopatologicznych

Najlepszy wybór: **Faster R-CNN**

Uzasadnienie

W analizie obrazów medycznych najważniejsza jest jak najwyższa dokładność detekcji, szczególnie że chodzi o wykrywanie bardzo małych, rzadkich komórek nowotworowych na obrazach o ogromnej rozdzielczości. W tym zastosowaniu czas przetwarzania pojedynczego obrazu ma znaczenie, ponieważ analiza może być wykonywana na wydajnym serwerze, a priorytetem jest ograniczenie liczby błędów.

Faster R-CNN będzie najlepszym wyborem, ponieważ jako detektor dwuetapowy zazwyczaj osiąga wyższą precyzję lokalizacji i klasyfikacji niż SSD. Dwuetapowy model lepiej sprawdza się w sytuacjach, gdzie obiekty są małe, trudne do odróżnienia od tła i wymagają bardziej precyzyjnej analizy.

Możliwość stosowania anchorów o różnych skalach i proporcjach też pomaga w wykrywaniu obiektów o niestandardowych rozmiarach. Więc w praktyce Faster R-CNN lepiej nadaje się do zadań, w których liczy się jakość detekcji bardziej niż szybkość działania.

Dlaczego nie pozostałe modele?

- **SSD** częściej ma problemy z małymi obiektami, szczególnie w gęstych i trudnych obrazach
- **R-CNN** też mógłby osiągać dobrą jakość, ale jego pipeline jest mniej efektywny i trudny w praktycznym treningu.

Scenariusz C: Historyczna analiza techniczna (rok 2014)

Najlepszy wybór: **R-CNN**

Uzasadnienie

Kluczowe jest ograniczenie historyczne: w roku 2014 nie ma jeszcze dostępnych rozwiązań dla nowoczesnej detekcji obiektów, ale potrzebny jest system lepszy niż klasyczne sliding window. W takim kontekście najlepszym wyborem jest **R-CNN**, ponieważ ten model był przełomem w przejściu do detekcji opartych na CNN.

R-CNN działa poprzez wygenerowanie propozycji regionów metodą **Selective Search**, a następnie klasyfikowanie każdego regionu za pomocą CNN. Choć takie podejście jest wolne i złożone, jest skuteczniejsze niż przesuwające się okno, ponieważ ogranicza liczbę analizowanych regionów do sensownych kandydatów, zamiast sprawdzania ogromnej liczby kandydatów na całym obrazie.

Dlaczego nie pozostałe modele?

- **Faster R-CNN** i **SSD** pojawiły się później